

Documentação de Modelagem Causal via DAG para dataset de emissões da produção leiteira

Por: Pedro José Campos de Almeida

1) Introdução

O objetivo deste documento é apresentar uma proposta de modelagem causal via DAG para um dataset de emissões da produção de leite, com o fim de servir como estrutura que guiará análises de dados sobre a pegada de carbono do leite e possíveis intervenções nesse processo (estratégias de mitigação).

As fontes de conhecimento de domínio utilizadas para consolidar a modelagem foram principalmente as orientações descritas no guia a seguir:

<https://www.infoteca.cnptia.embrapa.br/infoteca/bitstream/doc/1177308/1/Orientacoes-para-coleta-de-dados-para-calculo-de-pegada-de-carbono-do-leite.pdf>

Para cada relacionamento modelado, foram incluídos os trechos diretos do documento acima utilizados para fundamentar a decisão de modelagem.

1.1 Inferência Causal

A inteligência artificial e os modelos estatísticos tradicionais são excelentes para encontrar padrões nos dados, mas podem falhar em contextos críticos pela

regra fundamental de: correlação não é causalidade. Para que possamos gerar recomendações reais e aplicáveis — por exemplo, afirmar que a mudança para um determinado perfil de dieta reduzirá as emissões entéricas sem prejudicar a produtividade —, precisamos ir além da simples observação. A Inferência Causal nos ajuda com isso. Este documento foi criado especificamente para ser revisado e validado por especialistas do domínio. A matemática do modelo só funcionará corretamente se as premissas biológicas, agrônomicas e de manejo estiverem perfeitamente mapeadas.

A Inferência Causal é uma área da ciência de dados e estatística focada em analisar efeitos causais verdadeiros. Uma de suas tarefas é a realização de estimativas contra-factuais, onde se utiliza uma série de definições de causalidades associada a um conjunto de dados para obter resultados confiáveis para perguntas de “intervenções hipotéticas”, como “Como se comportaria a produtividade de todas as fazendas se elas seguissem o mesmo perfil de dieta animal?”.

1.2 DAGs (Grafos Acíclicos Direcionados) e Modelagem Causal

Para definir para o algoritmo qual a dinâmica causal real, nós utilizamos grafos do tipo DAG's (Directed Acyclic Graphs, em português Grafos Acíclicos Direcionados). Nas próximas páginas, haverá esquemas compostos por textos e setas. A leitura é: os nós (textos) representam as variáveis que medimos e coletamos; as setas ($\rightarrow$) representam uma relação direta de causalidade e efeito físico ou gerencial.

Exemplo: Se existe uma seta Raça do Gado $\rightarrow$ Peso do Animal, significa que, biologicamente, a raça causa variação no peso do animal.

A regra de ouro do DAG é: Uma seta só existe se uma intervenção forçada na variável de origem causar, no mundo real, uma alteração na variável de destino.

Como os DAGs funcionam na prática? A grande utilidade do DAG nesse contexto é ajudar o modelo a identificar e bloquear o que chamamos de variáveis de confusão (confounders). Imagine que queremos provar que o uso de fertilizantes aumenta as emissões totais da fazenda. Se olharmos apenas para os dados brutos, poderíamos chegar a conclusões erradas. Por quê? Porque uma fazenda com uma área de pastagem grande naturalmente gastará mais fertilizante e, por ser grande, terá um rebanho maior e emitirá mais carbono. Se não avisarmos o modelo de que a área causa o uso do fertilizante E também causa o tamanho das emissões, o modelo superestimar a "culpa" do fertilizante. O DAG serve exatamente como este mapa: ele avisa ao algoritmo quais fatores estruturais da fazenda ele

deve controlar estatisticamente para descobrir o verdadeiro peso de um tratamento ou intervenção pontual de uma variável.

1.3 Possibilidades

Ao cruzar os dados coletados no dataset disponível com o nosso Grafo Causal, poderemos performar análises estatísticas como estimar o efeito de tratamentos: descobrir exatamente em quantos % a mudança de um perfil de dieta A para um perfil B, por exemplo, altera as emissões entéricas. Podemos também evitar conclusões injustas: garantir que fazendas não sejam penalizadas nos cálculos apenas por estarem localizadas em solos mais pobres ou por terem sistemas de produção diferentes.

Podemos ainda simular cenários e medir níveis de incerteza para essas simulações, testando o impacto real com base na nossa ideia de causalidade de diferentes estratégias de mitigação para emissões.

1.4 Revisão

Pedimos que sejam avaliadas as setas (relacionamentos causais) propostas sob a ótica da experiência de campo e da literatura científica dos especialistas de domínio. A pergunta que você deve ser feita ao ler as próximas seções é: "Falta alguma conexão biológica ou logística essencial? Foram traçadas relações que não ocorrem na prática?".

1.5 Disclaimer: Data Leakage

Ao analisar o Grafo, você pode notar a ausência de algumas setas ou variáveis que parecem óbvias do ponto de vista contábil ou matemático. Por exemplo: se a produtividade individual é estimada pela razão entre o total de leite produzido e a média total de vacas em lactação, por que essas variáveis não estão conectadas? Ou por que não desenhamos a soma das emissões entéricas, energética, etc apontando para a emissão total?

A resposta está relacionada a um conceito crítico da modelagem estatística chamado Vazamento de Dados (Data Leakage) ou Multicolinearidade Perfeita.

Em modelos de inferência causal, o algoritmo procura explicar a variação de um desfecho analisando as relações e as incertezas da "física" do sistema. Se nós fornecemos a ele uma fórmula matemática fechada (onde a soma, razão ou multiplicação das partes explica 100% do resultado final), o modelo entra em colapso. Ele atinge uma precisão perfeita apenas reproduzindo a equação e fica "cego" para o que realmente nos interessa descobrir: os impactos de variáveis que não foram obtidas por cálculos.

Para proteger o rigor científico da análise e garantir que o modelo procure as verdadeiras alavancas de mitigação, isolamos as relações que imaginamos ser puramente matemáticas no dataset, não incluindo-as na modelagem.

Se um revisor tiver informações sobre alguma relação modelada que, no dataset em questão, é obtida por fórmula, então também destaque essa relação: será

necessário removê-la do modelo ou trocar a fonte de dados para remover a dependência matemática em 100% dos dados daquela variável.

2) Variáveis selecionadas

As variáveis escolhidas no dataset para performarmos nossas análises foram:

Property_Name
Location
Owner_Name
Information_Responsible
Predominant_Soil_Type
Lactating_Cows
Dry_Cows
Heifers
Calves
Bulls
Lactating_Cows_Weight
Dry_Cows_Weight
Heifers_Weight
Calves_Weight
Bulls_Weight
Females
Males
Cows_Discarded_Per_Year
Discarded_Cows_Destination
Productivity
Total_Milk_Production
Milk_Protein_Percentage
Milk_Fat_Percentage
Total
DMI_Check
Diesel
Gasoline
Other_Fuel
Electricity_Grid
Photovoltaic_Energy
Pasture_Area
Non_Organic_Fertilizer
Organic_Fertilizer
co2_enteric_fermentation
co2_manure_management
co2_fertilizer_emissions
co2_energy_emissions

As explicações e definições que considerei para todas essas variáveis foram extraídas dos documentos-base citados no início do documento.

Sobre as variáveis de alimentação, a proposta é a criação de uma variável global para representar perfis de dieta, que será referida aqui como:

Dietary_Strategy_Cluster

Essa variável pretende representar classes/tipos de dieta e a ideia é obter seus valores categóricos (grupo 0, grupo 1, grupo 2, etc) a partir de um algoritmo de agrupamento/clustering (machine learning não supervisionado) que divida bem os perfis de dieta encontrados para as instâncias do dataset com base nas distribuições dos dados de cada tipo de alimentação. Esse algoritmo ainda não foi realizado. Todas as variáveis de alimentação que seriam usadas na definição de Dietary_Strategy_Cluster são:

Grass_Fresh
Grass_Hay_On_Farm
Grass_Hay_Off_Farm
Grass_Silage_On_Or_Off_Farm
Maize_Silage
Lucerne_Alfalfa_Silage
Other_Fodder
Straw_Peanut_Hull_Others
Crop_Residues
Hay_Oat_Clover
Sorghum_Silage
Lucerne_Alfalfa_Hay
Wheat
Barley
Maize_Grain
Oats
Rice
Rye
Sorghum

Other_Cereals
DDG
Soybean_Meal_Hull
Sugarbeet_Molasses
Whey_Powder
Rapeseed_Cake_Meal
Sunflower_Cake_Meal
Cottonseed_Cake_Meal
Beans_Peas
Cassava_Tapioca
Citrus_Pulp
Brewers_Grain_Brewery_Residue
Other_Feed
Milk_Powder_Dry_Matter
Mineral_Mix

3) Relacionamentos modelados

3.1 Emissões de energia

Primeiramente, foram modelados os relacionamentos entre as variáveis relacionadas ao consumo energético e de combustíveis às emissões associadas à energia.

Diesel → co2_energy_emissions;
Gasoline → co2_energy_emissions;
Other_Fuel → co2_energy_emissions;
Electricity_Grid → co2_energy_emissions;
Photovoltaic_Energy → co2_energy_emissions;

3.2 Emissões de fertilizantes

Também simples, as relações entre uso de fertilizantes e suas emissões.

Non_Organic_Fertilizer → co2_fertilizer_emissions;
Organic_Fertilizer → co2_fertilizer_emissions;

3.3 Impactos do tipo de solo

“Tipo de solo predominante: A informação poderá ser utilizada para identificar

aptidão de produção, manejo agrícola (adubação), capacidade de remoção de carbono etc.” Orientações para coleta de dados para cálculo de pegada de carbono do leite pág.6

Predominant_Soil_Type →
Dietary_Strategy_Cluster;
Predominant_Soil_Type →
Non_Organic_Fertilizer;
Predominant_Soil_Type →
Organic_Fertilizer;
Predominant_Soil_Type →
co2_fertilizer_emissions;

A primeira relação foi incluída, pois creio que a aptidão de produção mencionada pode se refletir no perfil de dieta disponível aos animais. As demais foram incluídas pensando no manejo agrícola mencionado, e também foi adicionada uma seta para as emissões diretamente pensando no efeito sequestrador que o solo pode gerar.

3.4 Tamanhos de rebanho

“A quantidade de animais compõe o rebanho e a distribuição do número de cabeças em cada categoria animal (bezerras, novilhas, vacas secas, vacas em lactação e touros) é essencial para a compreensão da dinâmica da fazenda, nível de evolução, eficiência reprodutiva. Além disso, a informação é usada para o cálculo de emissões diretas indiretas dos animais. Como a emissão metano entérico que é resultante do processo digestório dos ruminantes e a emissão de metano e óxido nitroso do manejo dos dejetos.”

Orientações para coleta de dados para cálculo de pegada de carbono do leite pág.8

Eficiência reprodutiva:

Lactating_Cows → Females;

Lactating_Cows → Males;
Dry_Cows → Females;
Dry_Cows → Males;

Dinâmica de emissão:

Lactating_Cows →
co2_enteric_fermentation;
Dry_Cows → co2_enteric_fermentation;
Heifers → co2_enteric_fermentation;
Calves → co2_enteric_fermentation;
Bulls → co2_enteric_fermentation;
Lactating_Cows →
co2_manure_management;
Dry_Cows → co2_manure_management;
Heifers → co2_manure_management;
Calves → co2_manure_management;
Bulls → co2_manure_management;

Tamanho dos rebanhos é essencial para entender a quantidade total de alimentação usada na fazenda:

Lactating_Cows → Total;
Dry_Cows → Total;
Heifers → Total;
Calves → Total;
Bulls → Total;

Impacto na produção de leite advém das vacas em lactação:

Lactating_Cows →
Total_Milk_Production;

Geração de adubação orgânica in-farm:

Lactating_Cows → Organic_Fertilizer;
Dry_Cows → Organic_Fertilizer;
Heifers → Organic_Fertilizer;
Calves → Organic_Fertilizer;
Bulls → Organic_Fertilizer;

3.5 Impactos na composição do leite

“A composição do leite influencia o cálculo de PC. Os constituintes gordura e proteína têm alta variabilidade, associada, principalmente, à dieta, raça e produtividade.” Orientações para coleta de dados para cálculo de pegada de carbono do leite págs.7-8

Perfil de dieta e produtividade influenciam composição do leite:

Dietary_Strategy_Cluster →
Milk_Protein_Percentage;
Dietary_Strategy_Cluster →
Milk_Fat_Percentage;
Productivity → Milk_Protein_Percentage;
Productivity → Milk_Fat_Percentage;

3.6 Impactos dos pesos dos animais

“A informação de peso dos animais influencia diretamente o cálculo de emissão e a falta de precisão afetará a acurácia do resultado, além de comprometer o ajuste da dieta adequada para os animais.” Orientações para coleta de dados para cálculo de pegada de carbono do leite pág.9

Influência nos cálculos de emissão:

Lactating_Cows_Weight →
co2_enteric_fermentation;
Lactating_Cows_Weight →
co2_manure_management;
Dry_Cows_Weight →
co2_enteric_fermentation;
Dry_Cows_Weight →
co2_manure_management;
Heifers_Weight →
co2_enteric_fermentation;
Heifers_Weight →
co2_manure_management;
Calves_Weight →
co2_enteric_fermentation;
Calves_Weight →
co2_manure_management;
Bulls_Weight →
co2_enteric_fermentation;
Bulls_Weight →
co2_manure_management;

Peso ditando a demanda nutricional (o "ajuste da dieta"):

Lactating_Cows_Weight → Total;
Dry_Cows_Weight → Total;
Heifers_Weight → Total;

Calves_Weight → Total;
Bulls_Weight → Total;

3.7 Impactos da estratégia de dieta

Perfil de dieta pode influenciar direta e significativamente no ganho de peso para os animais em fases de crescimento.

Dietary_Strategy_Cluster →
Calves_Weight;
Dietary_Strategy_Cluster →
Heifers_Weight;

Foram adicionados os impactos mais amplos, como em produtividade, alimentação total e nas emissões.

Dietary_Strategy_Cluster → Total;
Dietary_Strategy_Cluster →
co2_enteric_fermentation;
Dietary_Strategy_Cluster →
co2_manure_management;
Dietary_Strategy_Cluster → Productivity;

3.8 Impactos da área de pastagem

A disponibilidade de terra pode ditar a viabilidade de certas dietas, influenciando diretamente na decisão estratégica em si.

Pasture_Area →
Dietary_Strategy_Cluster;

Ademais, pode influenciar nas decisões de adubação.

Pasture_Area → Non_Organic_Fertilizer;
Pasture_Area → Organic_Fertilizer;

3.9 Fronteira do sistema

“Bovinos machos destinados recém-nascidos não são contabilizados como saídas do sistema.” Orientações para coleta de dados para cálculo de pegada de carbono do leite pág.9

Em minhas pesquisas, vi sobre o fato de que, em inventários de carbono de

fazendas leiteiras, os bezerros machos recém-nascidos cruzam a fronteira do sistema produtivo imediatamente (são vendidos ou descartados), transferindo o papel de suas emissões e consumo para a cadeia de corte. Nesse caso, apenas as bezerras (Females), que permanecerão na fazenda como reposição do rebanho, causam demanda real por alimentação (Total) e contribuem ativamente para as emissões entéricas e de dejetos do sistema de produção do leite.

Females → Total;

Females → co2_enteric_fermentation;

Females → co2_manure_management;

4) Variáveis adicionais

Notei a existência de algumas variáveis do ciclo de vida que não estão presentes no dataset. De qualquer forma, é importante a necessidade de incluí-las no grafo, para representar corretamente a realidade biológica e gerencial da fazenda, alertando o modelo matemático sobre a existência de fatores de confusão não observados (unobserved confounders). Isso permite ao algoritmo entender que o cálculo de mitigação de carbono possui pontos cegos, possibilitando rodar testes de estresse matemáticos e processos de refutações das inferências causais.

4.1 Raça predominante do rebanho

A primeira variável faltante é a raça predominante do rebanho, referida como `Cattle_Breed` e modelada com os relacionamentos abaixo.

“A raça predominante do rebanho é outra informação que poderá ser utilizada para

avaliar a qualidade dos dados. Está associada principalmente à produtividade individual, composição do leite e peso médio dos animais. A indicação da raça predominante além de ser considerada na definição de fatores de cálculo, pode subsidiar a complementação de informações faltantes ou na validação de algum dado inconsistente, como peso, produtividade e consumo animal”

Orientações para coleta de dados para cálculo de pegada de carbono do leite págs.6-7

Cattle_Breed → Productivity;

Cattle_Breed → Milk_Protein_Percentage;

Cattle_Breed → Milk_Fat_Percentage;

Cattle_Breed → Lactating_Cows_Weight;

Cattle_Breed → Dry_Cows_Weight;

Cattle_Breed → Heifers_Weight;

Cattle_Breed → Calves_Weight;

Cattle_Breed → Bulls_Weight;

4.2 Sistema de produção empregado

Um dado categórico do sistema de produção (`Production_System`) usado no ciclo de vida é importante e seria capaz de enriquecer os relacionamentos com a estratégia dietária, as emissões relacionadas ao manejo de dejetos e de fertilizantes.

Production_System →

Dietary_Strategy_Cluster;

Production_System →

co2_manure_management;

Production_System →

Non_Organic_Fertilizer;

Production_System → Organic_Fertilizer;

5) Emissões totais

Como pôde-se notar, os dados de emissões totais não foram incluídos na modelagem. Como explicado na seção 1.5,

não podemos incluir dados advindos puramente de relações matemáticas na nossa modelagem causal. Por isso, mesmo que todos os tipos de emissão de fato causem as emissões totais, no dataset esse dado é obtido pela soma de todos os dados de tipo de emissão e, portanto, esse relacionamento não deve ser modelado.

Caso alguma análise tenha interesse em estimar algum efeito nas emissões totais, basta incluir a variável de emissões totais e fazer todas as setas (relacionamentos) que apontam para as variáveis de algum tipo de emissão apontarem para a variável de emissões totais. Depois, as variáveis de emissões específicas devem ser removidas.

Além disso, para o grafo final, aquelas variáveis que ficaram isoladas (sem relacionamentos) foram removidas. A saber, elas são:

Property_Name

Location

Owner_Name

Information_Responsible

DMI_Check

Cows_Discarded_Per_Year

Discarded_Cows_Destination